

## Zahlensysteme und Textcodierung

## 2 Zahlen und Kodierung

2.1 Kodierung

2.2 Bits und Bytes

2.3 Zahlssysteme 1 (natürliche Zahlen)

2.4 Konvertierung

2.5 Zahlssysteme 2 (ganze Zahlen)

2.6 Rechenoperation im Dualsystem

2.7 Zahlssysteme 3 (rationale und reelle Zahlen)

2.8 Textdarstellung

2.9 Umgang mit Dateien

Ein Positionssystem mit der Basis  $B$  ist ein Zahlensystem, in dem eine Zahl  $x$  nach Potenzen von  $B$  zerlegt wird.

Eine natürliche Zahl  $x$  wird durch folgende Summe dargestellt:

$$x = \sum_{i=0}^{n-1} b_i * B^i$$

Es gilt:

- $B$  = Basis des Zahlensystems ( $B \in \mathbb{N}, B \geq 2$ )

- $b_i$  = Ziffern ( $b_i \in \mathbb{N}_0, 0 \leq b_i < B$ )

- $n$  = Anzahl der Stellen

$$(11001)_2 = ( \quad ? \quad )_{10}$$

$$\begin{array}{ccccccc} 1 * 2^4 & + & 1 * 2^3 & + & 0 * 2^2 & + & 0 * 2^1 & + & 1 * 2^0 \\ 16 & + & 8 & & & & & + & 1 \\ & & & & & & & & = 25_{10} \end{array}$$

$$(315)_8 = ( \quad ? \quad )_{10}$$

$$\begin{array}{ccccccc} 3 * 8^2 & + & 1 * 8^1 & + & 5 * 8^0 \\ 3 * 64 & + & 1 * 8 & + & 5 * 1 \\ & & & & & & & = 205_{10} \end{array}$$

$$(C9)_{16} = ( \quad ? \quad )_{10}$$

$$\begin{array}{ccccccc} 12 * 16^1 & + & 9 * 16^0 \\ 192 & + & 9 \\ & & & & & & = 201_{10} \end{array}$$

# Konvertierung

- Konvertieren vom Dezimalsystem in andere Positionssysteme
  - Methode: **Division mit Rest**

# Methode: Division mit Rest

Teilen wir eine natürliche Zahl  $z$  (Dividend) durch eine andere natürliche Zahl  $d \neq 0$  (Divisor), erhalten wir einen Quotienten  $q$  und einen Rest  $r$ .

Es gilt dann offensichtlich der Zusammenhang:

$$z = q \cdot d + r \quad \text{mit } 0 \leq r < d$$

$z$  = Zahl,  $q$  = Quotient (entspr. Ergebnis der Division),  
 $d$  = Divisor (der „Teiler“),  $r$  = Rest

Wir unterscheiden

- die Operation des exakten Dividierens wird als `div` bezeichnet
- die Operation, die zwei Zahlen den Divisionsrest zuordnet, wird als `mod` bezeichnet.

Beispielsweise gilt:

- `5000 div 16 = 312` und
- `5000 mod 16 = 8` denn: `5000 : 16 = 312 Rest 8`

Die obige Gleichung können wir unter Zuhilfenahme der Operatoren `div` und `mod` allgemein schreiben als:

- $z = (z \text{ div } d) \cdot d + (z \text{ mod } d)$

# Konvertieren vom Dezimalsystem in andere Positionssysteme

Folgender Algorithmus kann zur Umwandlung einer Dezimalzahl  $x$  in ein Zahlensystem mit der Basis  $n$  verwendet werden:

1.  $x / n = y \text{ Rest } z$
2. Mache  $y$  zum neuen  $x$  und fahre wieder mit Schritt 1 fort, wenn dieses neue  $x$  ungleich 0 ist, ansonsten fahre mit Schritt 3 fort.
3. Die ermittelten Reste  $z$  von unten nach oben nebeneinander geschrieben ergeben dann die entsprechende Zahl im Ziel-Positionssystem mit der Basis  $n$

# Konvertieren vom Dezimalsystem ins Binärsystem

Beispiel:  $(76)_{10} \rightarrow (?)_2$

Zur Umrechnung dividiert man die Zahl in Dezimaldarstellung sukzessive durch 2 und merkt sich die Reste bei diesen Divisionen. In umgekehrter Folge eingesammelt ergibt dies die Zahl in Binärdarstellung.

( )<sub>2</sub>



# Konvertieren vom Dezimalsystem ins Binärsystem

Beispiel:  $(76)_{10} \rightarrow (?)_2$

$76 / 2 = 38$ ; Rest 0

$38 / 2 = 19$ ; Rest 0


$19 / 2 = 9$ ; Rest 1

$9 / 2 = 4$ ; Rest 1

$4 / 2 = 2$ ; Rest 0

$2 / 2 = 1$ ; Rest 0

$1 / 2 = 0$ ; Rest 1



# Konvertieren vom Dezimalsystem ins Hexadezimalsystem

Beispiel:  $(24572)_{10} \rightarrow (?)_{16}$

Unser Verfahren zur Umrechnung funktioniert auch für die Basen 8 und 16

$24572 / 16 = 1535$ ; Rest 12

$1535 / 16 = 95$ ; Rest 15

$95 / 16 = 5$ ; Rest 15

$5 / 16 = 0$ ; Rest 5



( 5 F F C )<sub>16</sub>

# Konvertierung

- Konvertierung von anderen Systemen in das Dezimalsystem
  - Methode: **Horner-Schema**

# Konvertierung von anderen Systemen in das Dezimalsystem via Horner

- Eine im Positionssystem mit Basis B dargestellte natürliche Zahl n:

$$n = \sum_{i=0}^N b_i \times B^i$$

- lässt sich mit Hilfe des Hornerschemas wie folgt darstellen:

$$n = (...(((b_N \times B + b_{N-1}) \times B + b_{N-2}) \times B + b_{N-3}) \times B + ... + b_1) \times B + b_0$$

- Das Horner-Schema ist ein Umformungsverfahren für Polynome
  - Polynomdivision, Berechnung von Nullstellen und von Ableitungen
  - Ermöglicht damit auch Umrechnungen von beliebigen Zahlensystemen
- Mit Hilfe dieser Darstellung können Konvertierungen in das Dezimalsystem durchgeführt werden

# Horner-Schema: $(11011101)_2 \rightarrow (?)_{10}$

$$p(2) = \left( \left( \left( \left( \left( \left( (1)2 + 1 \right) 2 + 0 \right) 2 + 1 \right) 2 + 1 \right) 2 + 1 \right) 2 + 0 \right) 2 + 1$$

$B_n$	$B_{n-1}$	$B_{n-2}$	$B_{n-3}$	$B_{n-4}$	$B_{n-5}$	$B_{n-6}$	$B_{n-7}$

Wir spiegeln die Formel

$$p(2) = 1 + 2(0 + 2(1 + 2(1 + 2(1 + 2(0 + 2(1 + 2(1)))))))$$

$B_{n-7}$							$B_n$

# Wir verwenden Hilfsvariable $t_0$ bis $t_n$

$$p(x) = b_0 + x(b_1 + x(\dots + x(b_{n-2} + x(b_{n-1} + xb_n))\dots))$$

$$t_0 := b_n$$

$$t_1 := b_{n-1} + xb_n = b_{n-1} + xt_0$$

$$t_2 := b_{n-2} + x(b_{n-1} + xb_n) = b_{n-2} + xt_1$$

$$t_3 := b_{n-3} + x(b_{n-2} + x(b_{n-1} + xb_n)) = b_{n-3} + xt_2$$

$$t_n := b_0 + x(b_1 + x(\dots + x(b_{n-2} + x(b_{n-1} + xb_n))\dots)) = b_0 + xt_{n-1}$$

# Horner-Schema: $(11011101)_2 \rightarrow (221)_{10}$

$$(11011101)_2$$

$$p(2) = 1 + 2(0 + 2(1 + 2(1 + 2(1 + 2(0 + 2(1 + 2 \times 1))))))$$

$$t_0 := 1$$

$$t_1 := 1 + 2 \times 1 = 1 + 2 \times t_0$$

$$t_2 := 0 + 2(1 + 2 \times 1) = 0 + 2 \times t_1$$

$$t_3 := 1 + 2(0 + 2(1 + 2 \times 1)) = 1 + 2 \times t_2$$


$$t_4 := 1 + 2(1 + 2(0 + 2(1 + 2 \times 1))) = 1 + 2 \times t_3$$

$$t_5 := 1 + 2(1 + 2(1 + 2(0 + 2(1 + 2 \times 1)))) = 1 + 2 \times t_4$$

$$t_6 := 0 + 2(1 + 2(1 + 2(1 + 2(0 + 2(1 + 2 \times 1)))))) = 0 + 2 \times t_5$$

$$t_7 := 1 + 2(0 + 2(1 + 2(1 + 2(1 + 2(0 + 2(1 + 2 \times 1)))))) = 1 + 2 \times t_6$$

Horner-Schema:  $(11011101)_2 \rightarrow (221)_{10}$



Für die blauen Werte gilt.  $1=t_0$ ,  $3=t_1$ ,  $6=t_2$ , ...,  $221=t_7$



# Konvertierung Zusammenfassung

- Konvertieren vom Dezimalsystem in andere Positionssysteme
  - Methode: **Division mit Rest**
- Konvertierung von anderen Systemen in das Dezimalsystem
  - Methode: **Summenformel**
  - Methode: **Horner-Schema**

## 2 Zahlen und Kodierung

2.1 Kodierung

2.2 Bits und Bytes

2.3 Zahlssysteme 1 (natürliche Zahlen)

2.4 Konvertierung

2.5 Zahlssysteme 2 (ganze Zahlen)

2.6 Rechenoperation im Dualsystem

2.7 Zahlssysteme 3 (rationale und reelle Zahlen)

2.8 Textdarstellung

2.9 Umgang mit Dateien

- Sie kennen die Möglichkeiten der Vorzeichenbehandlung
- Sie können die Methode 2er-Komplement für negative ganze Zahlen erläutern

# Darstellung ganzer Zahlen – Vorzeichendarstellung (Einerkomplement)

- Bisher betrachtet: Natürliche Zahlen (positive, ganze Zahlen)
- Ganze Zahlen schließen negative Zahlen mit ein
- Folglich sind der absolute Zahlenwert und das Vorzeichen von Bedeutung
- Naheliegende Möglichkeit?
  - Das Vorzeichen wird über das führende Bit ausgedrückt.  
0 → positive Zahl; 1 → negative Zahl
  - Man spricht von der **Vorzeichendarstellung**
- Beispiel: Vorzeichendarstellung in 4 Bit:


Quelle: <http://www.hki.uni-koeln.de/>

0000 = +0	0100 = +4	1000 = -0	1100 = -4
0001 = +1	0101 = +5	1001 = -1	1101 = -5
0010 = +2	0110 = +6	1010 = -2	1110 = -6
0011 = +3	0111 = +7	1011 = -3	1111 = -7

- Bei näherer Betrachtung hat die Vorzeichendarstellung eine Reihe von Nachteilen:
  - Die Zahl 0 wird durch zwei verschiedene Bitfolgen dargestellt (als '+0' und als '-0').
  - Das Rechnen ist komplizierter geworden. Es ist nicht mehr so einfach möglich, Zahlen untereinander zu schreiben und zu addieren.
- Die Zweierkomplementdarstellung ist eine Variante, die diese Probleme vermeidet und deshalb zu einer gebräuchlichen Darstellung geworden ist.

# Die Zweierkomplementdarstellung

- Zweierkomplementdarstellung ist die gebräuchliche interne Repräsentation ganzer positiver und negativer Zahlen
- Beispiel (4 Bit): Zahlenbereich von  $2^4 = 16$  abdeckbar.
  - Der Bereich ist frei wählbar, also z.B. die 16 Zahlen von -8 bis +7
  - Um Dezimalzahlen abzubilden, wird von 0 beginnend aufwärts gezählt, bis die obere Grenze (+7) erreicht ist. Anschließend wird an der unteren Grenze (-8) fortgefahren und aufwärts gezählt, bis zur Zahl -1



1000 = -8	1100 = -4	0000 = 0	0100 = 4
1001 = -7	1101 = -3	0001 = 1	0101 = 5
1010 = -6	1110 = -2	0010 = 2	0110 = 6
1011 = -5	1111 = -1	0011 = 3	0111 = 7

Quelle: <http://www.hki.uni-koeln.de/>

- Nun offenbart sich, wieso für 4 Bit der Bereich von -8 bis +7 gewählt wurde:
  - Bei dem mit 0 beginnenden Hochzählen wird bei der neunten Bitfolge zum ersten Mal das erste Bit zu 1 (Bei den Zweierkomplementzahlen stellt das erste Bit das Vorzeichen dar; d.h. man springt ab der 9. Bitfolge in den negativen Bereich).
  - Weiterer Vorteil: Die „0“ kommt nur einmal vor
  - Darstellbar Wertebereich mit dem Zweierkomplement: Zahlen von  $-2^{N-1}$  bis  $2^{N-1}-1$
  - Zweierkomplementzahlen werden auch als *signed binary numbers* oder *signed integers* bezeichnet

## Einerkomplement

1000 = -0	1100 = -4
1001 = -1	1101 = -5
1010 = -2	1110 = -6
1011 = -3	1111 = -7

## Zweierkomplement

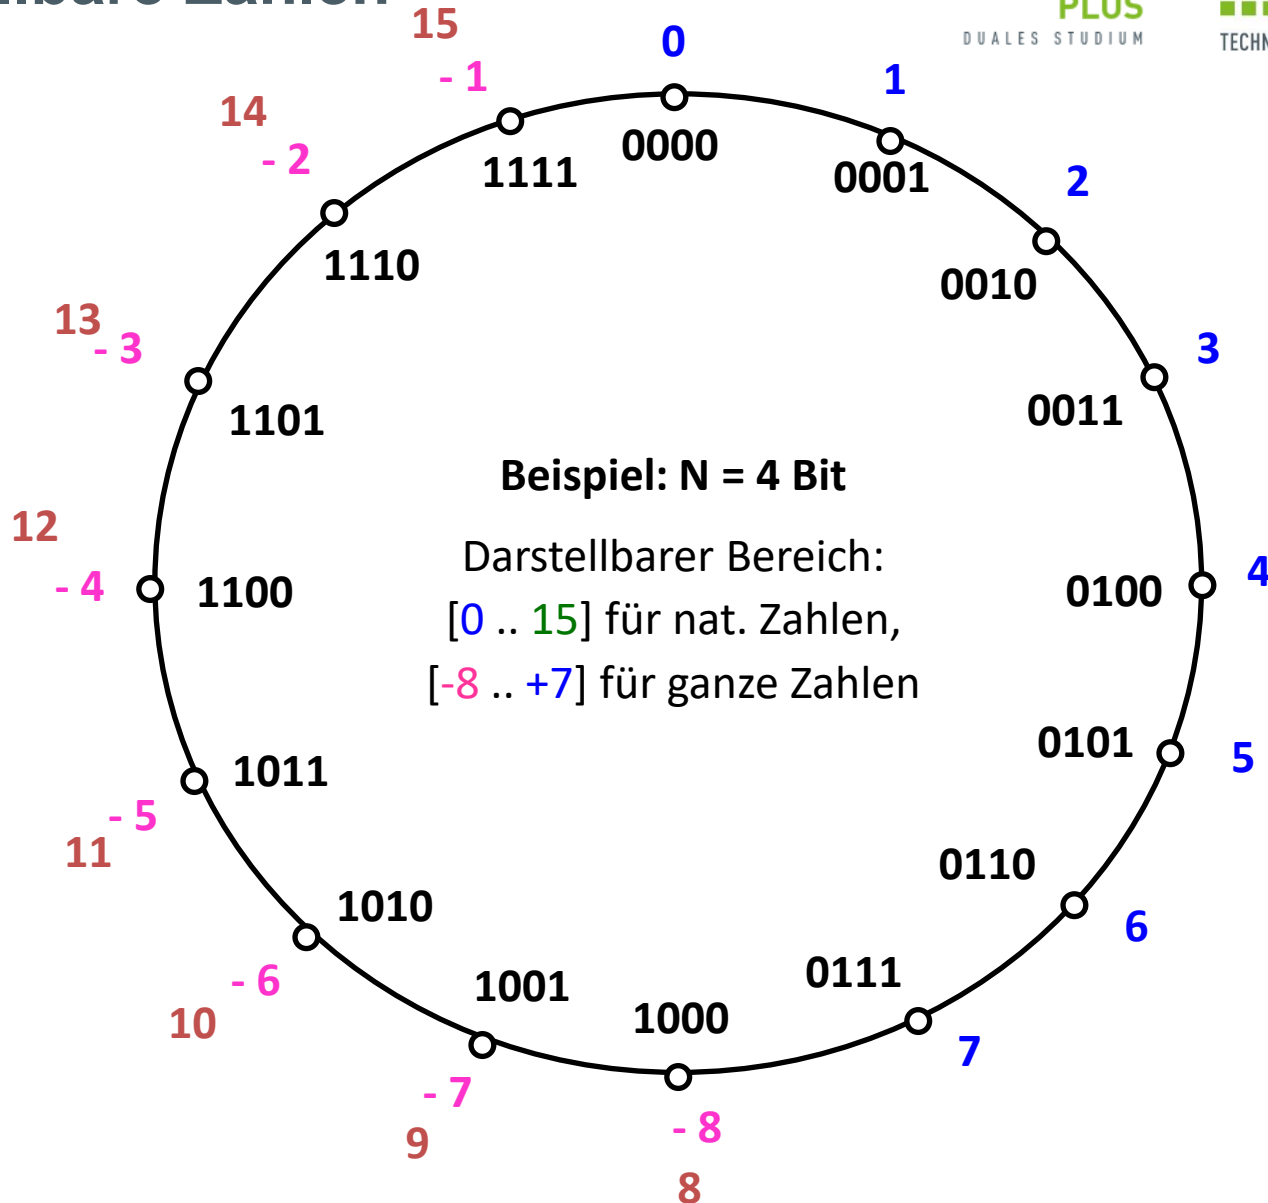
1000 = -8	1100 = -4
1001 = -7	1101 = -3
1010 = -6	1110 = -2
1011 = -5	1111 = -1



- Das Einerkomplement lässt sich durch bitweises Vertauschen der Werte 0 und 1 erhalten (Invertierung)
- Das Zweierkomplement resultiert aus Bildung des Einerkomplements und anschließender Addition von 1
- Algorithmus:
  - Die gewünschte Zahl wird binär codiert
  - Die binäre Darstellung wird invertiert
  - Zur Invertierten Darstellung wird (binär) eins addiert
- Beispiel: Zweierkomplementdarstellung von -5

1. Binärcodierung	$(0101)_2 = (5)_{10}$
2. Invertierung	$(1010)_2$
3. Addition +1	$(1011)_2$

# Darstellbare Zahlen



## 2 Zahlen und Kodierung

2.1 Kodierung

2.2 Bits und Bytes

2.3 Zahlssysteme 1 (natürliche Zahlen)

2.4 Konvertierung

2.5 Zahlssysteme 2 (ganze Zahlen)

2.6 Rechenoperation im Dualsystem

2.7 Zahlssysteme 3 (rationale und reelle Zahlen)

2.8 Textdarstellung

2.9 Umgang mit Dateien

# Addition von Binärzahlen

Die Addition von Binärzahlen folgt direkt der bekannten schriftlichen Addition von Dezimalzahlen.

$$\begin{array}{r} 0111 \ 0000 \\ + 0101 \ 0101 \\ \hline 1100 \ 0101 \end{array} \quad \begin{array}{l} (=112_{10}) \\ (=85_{10}) \\ (=197_{10}) \end{array}$$

Aber:

$$\begin{array}{r} 1100 \ 0000 \\ + 0101 \ 0101 \\ \hline 1 \ 0001 \ 0101 \end{array} \quad \begin{array}{l} (=192_{10}) \\ (=85_{10}) \\ (=277_{10}) \end{array} \quad \text{Überlauf!}$$

Bei dieser Addition wird der darstellbare Bereich verlassen!

Der Überlauf wird ignoriert.

Das kann bei jeder Wortbreite passieren – bei höherer Wortbreite erst bei größeren Zahlen.

# Subtraktion von Binärzahlen

Die Subtraktion wird im Binärsystem auf eine Negation (Zweier Komplement) mit anschließender Addition zurückgeführt.

Beispiel:  $(112)_{10} - (85)_{10} = (27)_{10}$

0 1 1 1 0 0 0 0      (= 112<sub>10</sub>)

0 1 0 1 0 1 0 1      (= 85<sub>10</sub>)

Zu                      (= -85<sub>10</sub>) kommen wir

1 0 1 0 1 0 1 0      = Einerkomplement

1 0 1 0 1 0 1 **1**      = Zweierkomplement

0 1 1 1 0 0 0 0      (= 112<sub>10</sub>)

+ 1 0 1 0 1 0 1 1      (= -85<sub>10</sub>)

-----

1 0 0 0 1 1 0 1 1      (= 27<sub>10</sub>)

Die erste Bit-Position (Endübertrag) bleibt unberücksichtigt, da bei der Umwandlung des Subtrahenden nur ein achtstelliger Wert berücksichtigt wurde.

# Woher kommt der Name?

Sei  $B$  die die Basis des Zahlensystem  
Im Falle  $B = 2$

Dann kann man das Einer-Komplement so schreiben:  $(B-1)$ -Komplement

Dann kann man das Zweier-Komplement so schreiben:  $(B)$ -Komplement

# Multiplikation und Division von Binärzahlen

- Multiplikation und Division funktionieren wie bei den Dezimalzahlen
- Multiplikation: Produkte werden untereinander geschrieben und addiert, eventuelle Überträge eine Stelle nach links mitgenommen
- Division:
  - Divisor unter erste Stelle des Dividenden schreiben und subtrahieren
  - Anschließend Ergebnisse von links nach rechts aufschreiben
  - Passt der Divisor mindestens einmal in die ersten Stellen des Dividenden, dann entsteht beim Ergebnis eine 1. Falls nicht, entsteht beim Ergebnis eine 0 und es muss eine weitere Stelle des Dividenden nach unten gezogen werden

<b>2</b>	<b>Zahlen und Kodierung</b>
2.1	Kodierung
2.2	Bits und Bytes
2.3	Zahlsysteme 1 (natürliche Zahlen)
2.4	Konvertierung
2.5	Zahlsysteme 2 (ganze Zahlen)
2.6	Rechenoperation im Dualsystem
2.7	Zahlsysteme 3 (rationale und reelle Zahlen)
2.8	Textdarstellung
2.9	Umgang mit Dateien



- Sie kennen die Möglichkeiten rationale und reelle zu kodieren
- Sie können Rechner-interne Darstellung nach IEEE-754 erläutern

- In einem endlichen Intervall liegen nur endlich viele ganze Zahlen, aber unendlich viele rationale bzw. reelle Zahlen.
- Zwei zentrale Fragen:
  - Wie lässt sich das Komma darstellen, wo 0 und 1 aus Kodierungssicht bereits belegt sind?
  - Wie lässt sich der unendliche Zahlenbereich zwischen zwei reellen Zahlen mit endlichen vielen Ziffern (Bits) darstellen?
- Lösung: **Gleitpunktdarstellung** (Kommastelle ist Bestandteil der Zahl)
- Wissenschaftliche Notation gibt die **Kommaposition** über einen **Exponenten** an.
- Beispielsweise kann die Zahl **3,84** auch so geschrieben werden:
  - $384 \cdot 10^{-2}$
  - $0,0384 \cdot 10^2$
  - $38,4 \cdot 10^{-1}$

- In der Praxis werden fast ausschließlich **Gleitpunktzahlen** für die Speicherung "reeller Zahlen" verwendet.
  - Beachte: Echte "reelle" Zahlen lassen sich nie genau in einem Computer speichern, da es für sie definitionsgemäß keine endliche Darstellung gibt.
  - Die sog. "*real numbers*" im Computer sind mathematisch gesehen immer rationale Zahlen, d.h. Näherungswerte für reelle Zahlen.
- Mit der **Gleitpunktdarstellung** möchte man:
  - ein möglichst großes Intervall "reeller" Zahlen umfassen,
  - die Genauigkeit der Darstellung an die Größenordnung der Zahl anpassen: bei kleinen Zahlen sehr hoch, bei großen Zahlen niedrig.
- Daher speichert man neben dem reinen Zahlenwert (**Mantisse**) auch einen **Exponenten** (i.d.R. zur Basis 2 oder 10), der die Kommaposition in der Zahl angibt.

- Die Gleitpunktdarstellung besteht aus folgenden Komponenten:
  - dem Vorzeichenbit: **V** (gibt an, ob die vorliegende Zahl positiv oder negativ ist)
  - der Mantisse: **M** (besteht aus Binärziffern  $m_1 \dots m_n$  und gibt den Wert der vorliegenden Zahl an)
  - dem Exponenten: **E**. (Der Exponent ist eine Binärzahl, zum Beispiel im Bereich -127 bis +127, die angibt, mit welcher Potenz einer **Basiszahl b** die vorliegende Zahl zu multiplizieren ist)
- Das Tripel (V, M, E) wird als  **$V \cdot M \cdot b^E$**  interpretiert.

- Eine zur Basis 2 **normierte Gleitpunktzahl** ist eine solche, bei der der Exponent so gewählt wird, dass die Zahl in der Form

$$\pm 1 . m_1 m_2 \dots m_{n-1} m_n \quad * \quad 2^E \quad \text{dargestellt werden kann.}$$

- **Motivation für eine Normierung:** Es soll für jede darstellbare Zahl genau eine Darstellung als Gleitpunktzahl existieren.
- Da durch die Normierung im Binärsystem immer eine 1 vor dem Komma stehen muss, kann man diese auch weglassen.
- In der Mantisse werden dann nur noch die Stellen hinter dem Komma notiert! (Die führende "1," steht also gedacht links vor der Mantisse.).
- Durch Einsparung der führenden 1 können die Mantissenbits optimal ausgenutzt werden, was besonders bei unendlich vielen Nachkommastellen (periodische Zahlen) eine höhere Rechengenauigkeit ermöglicht.

# Gleitpunktzahlen nach IEEE 754

- Nach IEEE 754 (Institute of Electrical and Electronics Engineers) normierte Gleitpunktzahlen verwenden  $b = 2$  als Basiszahl.
- Zwei von IEEE verabschiedete Normen werden heute in den meisten Rechnern verwendet:

Typ	Bit	Aufteilung
short real, auch float (einfache Genauigkeit)	32	V = 1 Bit, E = 8 Bit, M = 23 Bit
long real. auch double (doppelte Genauigkeit)	64	V = 1 Bit, E = 11 Bit, M = 52 Bit

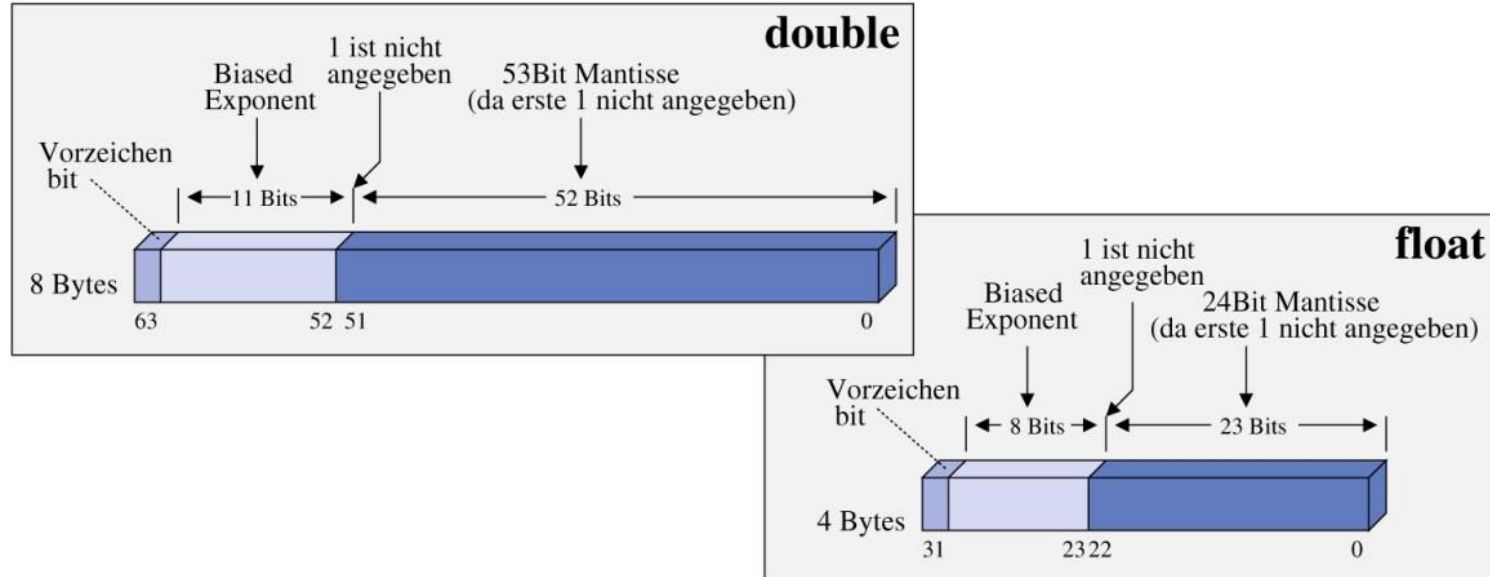


Abbildung 3.4: IEEE-Format für float und double

# Konvertierung reeller Zahlen in 32-Bit IEEE 754 Gleitpunktzahlen / 1

1. Das Vorzeichen wird mit 0 (pos. Zahlen) und 1 (neg. Zahlen) codiert.
2. Konvertierung des ganzzahligen Anteils.
3. Der gebrochene Anteil wird sukzessive mit 2 multipliziert.
  - a. Wenn das Ergebnis größer (oder gleich) 1 ist, wird 1 subtrahiert und eine 1 als Ergebnis notiert.
  - b. Wenn das Ergebnis kleiner als 1 ist, wird erneut mit 2 multipliziert und eine 0 als Ergebnis notiert.
  - c. Diese Berechnung wird solange wiederholt, bis das Ergebnis gleich 0 ist.
  - d. (Achtung! Dieser Prozess kann unendlich lange fortschreiten. Die Genauigkeit der Berechnung wird durch die für die Mantisse verfügbare Anzahl der Stellen begrenzt!)
4. Das Ergebnis wird als Festkomma-Zahl notiert.


# Konvertierung reeller Zahlen in 32-Bit IEEE 754 Gleitpunktzahlen / 2

5. Die Festkomma-Zahl wird normiert, d.h. das Komma wird so weit nach rechts oder links verschoben, bis vor dem Komma eine 1 steht.
6. Die Anzahl der Stellen, um die das Komma verschoben wird, ergibt den Wert des Exponenten.
7. Wird das Komma nach rechts verschoben, ist der Exponent negativ, wird er nach links verschoben, ist der Exponent positiv.
8. Der Exponent  $e$  wird als natürliche Zahl  $e'$  codiert mit Wert  $e' = e + 127$  (BIAS).  $e'$  ist der „biased exponent“.
9. Die Nachkommastellen (!) werden genommen und auf die Breite der Mantisse nach rechts mit Nullen aufgefüllt.
10. Die Bits werden in der Reihenfolge Vorzeichen - Exponent - Mantisse angeordnet.



Für eine IEEE-754 Gleitkommazahl benötigt man:

- **Vorzeichen** der Mantisse (1 Bit, 0 bei pos. oder 1 bei neg. Zahl)
- **Mantisse** (Binär, normiert, 1 links vom Komma wird nicht dargestellt)
- **Exponent** (Binäre Ganzzahl; Vorzeichenloses Binärformat nach Addition eines sogenannten Bias; Wert des Bias abhängig vom Genauigkeitsgrad – short real = 127, long real = 1023)
- Beispiel:  $(17,625)_{10}$  entspricht der Binärzahl  $1,0001101 \cdot 2^4$



- Biased Exponent ergibt sich als:

Bias =	0111 1111 = $(127)_{10}$
+ wirkl. Exp. =	0000 0100 = $(4)_{10}$
	1000 0011 = $(131)_{10}$

# Beispiel

Wie wird die Dezimalzahl 13, 875 als Gleitkommazahl im Format *real short* dargestellt?

0	Vorüberlegung	<div><div>V</div><div>CCCCCCCC</div><div>MMMMMMMMMMMMMMMMMMMMMMMMMMMM</div></div> <div><div>Vor- zeichen</div><div>Charakteristik</div><div>Mantisse</div></div> <div><div>1</div><div>8</div><div>23</div></div>
1	Das Vorzeichen wird mit 0 (pos. Zahlen) und 1 (neg. Zahlen) codiert	Vorzeichen von $13,875_{10}$ betrachten: Positiv, somit <b>0</b>
2	Konvertierung des ganzzahligen Anteils	Vorkommazahl in Binär $13 = \mathbf{1101}$
3	Der gebrochene Anteil wird sukzessive mit 2 multipliziert. a) Wenn das Ergebnis größer (oder gleich) 1 ist, wird 1 subtrahiert und eine 1 als Ergebnis notiert. b) Wenn das Ergebnis kleiner als 1 ist, wird erneut mit 2 multipliziert und eine 0 als Ergebnis notiert. a. Diese Berechnung wird solange wiederholt, bis das Ergebnis gleich 0 ist.	<div>Nachkommazahl in Binär    <math>0,875 \cdot 2 = 1,75</math>    <b>1</b></div> <div><math>0,75 \cdot 2 = 1,5</math>    <b>1</b></div> <div><math>0,5 \cdot 2 = 1</math>    <b>1</b></div> <div><math>0 \cdot 2 = 0</math>    <b>0</b></div> <div><div>Leserichtung ↓</div></div> <div>Hinweis</div> <div><math>\dots\dots\dots 2^2 + 2^1 + 2^0</math>    <math>2^{-1} + 2^{-2} + 2^{-3} + \dots</math></div> <div><div>←    </div></div>

# Beispiel

5	Die Festkomma-Zahl wird normiert, d.h. das Komma wird so weit nach rechts oder links verschoben, bis vor dem Komma eine 1 steht.	$1\ 1\ 0\ 1,111$ $1\ 1\ 0,1111\ 1$ $1\ 1,01111\ 2$ $1,101111\ 3$ Die Mantisse lautet <b>101111</b> .
6	Die Anzahl der Stellen, um die das Komma verschoben wird, ergibt den Wert des Exponenten.	Anzahl der verschobenen Stellen: 3 bzw. Multiplikation der Zahl mit $2^3$ somit Exponent = 3
7	Wird das Komma nach rechts verschoben, ist der Exponent negativ, wird er nach links verschoben, ist der Exponent positiv.	Der Exponent ist positiv, da das Komma nach links verschoben wurde
8	Der Exponent e wird als natürliche Zahl e' codiert mit Wert $e' = e + 127$ (BIAS). e' ist der „biased exponent“.	$\text{Bias} + \text{Exponent} = \text{Charakteristik}$ $127 + 3 = 130$ $= 128 + 2$ in Binär: <b>10000010</b> Hinweis: Dezimal in Dual, dann +127. Dual in Dezimal, dann -127
9	Die Nachkommastellen (!) werden genommen und auf die Breite der Mantisse nach rechts mit Nullen aufgefüllt.	$1$ MMMMMMMMMMMMMMMMMMMMMMMM 101111000000000000000000
10	Reihenfolge Vorzeichen - Exponent - Mantisse angeordnet.	$V$ CCCCCCCC                      MMMMMMMMMMMMMMMMMMMMMMMM $0$ 10000010                      101111000000000000000000 In Hex 0100 0001 0101 1110 0000 0000 0000 0000 4      1      5      E      0      0      0      0

# Formel für die Darstellung einer Gleitpunktzahl im IEEE-Format

$$(-1)^S \times (2^{B-bias}) \times (1.f_N \dots f_0)$$

↑  
SIGN.

EXPONENT. B = Biased Exponent (zu speichernder Exp.)

MANTISSE.

N=22 (float = 23 Stellen);  
N=51 (double = 52 Stellen);

SIGN. S = 0 (positiv); S = 1 (negativ)

Beispiel:

V	Exponent ----->	Mantisse ----->
0	1 0 0 0 0 0 1 1	0 0 0 1 1 0 1 0 0 0 0 0 0 0 ... 0

$$\rightarrow (-1)^0 \times (2^{131-127}) \times (1.0001101)$$

$$\rightarrow = 1 \times 2^4 \times 1,0001101 = (17,625)_{10}$$

# Gegenüberstellung *float* und *double* nach IEEE-754

	einfach (float)	doppelt (double)
Vorzeichen-Bits	1	1
Exponenten-Bits	8	11
Mantissen-Bits	23	52
Bits insgesamt	32	64
BIAS	127	1023
Exponentenbereich	$[-126, 127]$	$[-1022, 1023]$

## Sonderfälle des IEEE-Formats:

Biased Exponent	Mantisse	Bedeutung
111..111 (=255 bzw. =2047)	$\neq 0$	not a number
111..111 (=255 bzw. =2047)	000..000 (=0)	$\pm\infty$
000..000 (=0)	000..000 (=0)	$\pm 0$

<b>2</b>	<b>Zahlen und Kodierung</b>
2.1	Kodierung
2.2	Bits und Bytes
2.3	Zahlsysteme 1 (natürliche Zahlen)
2.4	Konvertierung
2.5	Zahlsysteme 2 (ganze Zahlen)
2.6	Rechenoperation im Dualsystem
2.7	Zahlsysteme 3 (rationale und reelle Zahlen)
2.8	Textdarstellung
2.9	Umgang mit Dateien

- Um Texte in einem Rechner darzustellen, codiert man Alphabet und Satzzeichen in **Bitfolgen**.
- Mit einem Alphabet von 26 Kleinbuchstaben, ebenso vielen Großbuchstaben, einigen Satzzeichen wie etwa Punkt, Komma und Semikolon und Spezialzeichen wie '+', '&', '%' hat eine normale Schreibmaschinentastatur eine Auswahl von knapp 100 Zeichen.
- Die Information, wo ein Zeilenumbruch stattfinden oder wo ein Text eingerückt werden soll, codiert man ebenfalls wie ein Zeichen.
- Beispiele:
  - das **CR-Zeichen** (von englisch **C**arriage **R**eturn = Wagenrücklauf),
  - das **LF-Zeichen** (von englisch **L**ine **F**eed = Zeilenvorschub),
  - das Tabulatorzeichen **Tab**.
- Diese Zeichen haben bei der Darstellung von Text eine formatierende Wirkung, werden aber nicht als Zeichen gedruckt. Sie heißen daher auch **nicht-druckbare Zeichen**.

- Mit einem Byte (= 8 Bits) kann man  $2^8 = 256$  verschiedene Zeichen darstellen.
- Um Texte mit Hilfe von Bitfolgen zu speichern, bedarf es einer Vorschrift, die den Zeichen eines Zeichensatzes eindeutig Byte(-nummern) zuordnet. Eine solche Zuordnungsvorschrift nennt man einen **Code**. Häufig verwendete und international akzeptierte Codes sind:
  - **ASCII: American Standard Code of Information Interchange**
  - **EBCDIC: Extended Binary Codes Decimal Interchange Code**
- Diese Codes folgen einer gewissen Systematik, so stehen z.B.
  - alle Kleinbuchstaben,
  - alle Großbuchstaben,
  - die Ziffern 0 bis 9in ihrer "natürlichen" Reihenfolge.
- Die folgende Tabelle enthält einige Beispiele für die Zuordnung von Bytes zu verschiedenen Zeichen.



# ASCII TABLE

Decimal	Hex	Char	Decimal	Hex	Char	Decimal	Hex	Char	Decimal	Hex	Char
0	0	[NULL]	32	20	[SPACE]	64	40	@	96	60	`
1	1	[START OF HEADING]	33	21	!	65	41	A	97	61	a
2	2	[START OF TEXT]	34	22	"	66	42	B	98	62	b
3	3	[END OF TEXT]	35	23	#	67	43	C	99	63	c
4	4	[END OF TRANSMISSION]	36	24	\$	68	44	D	100	64	d
5	5	[ENQUIRY]	37	25	%	69	45	E	101	65	e
6	6	[ACKNOWLEDGE]	38	26	&	70	46	F	102	66	f
7	7	[BELL]	39	27	'	71	47	G	103	67	g
8	8	[BACKSPACE]	40	28	(	72	48	H	104	68	h
9	9	[HORIZONTAL TAB]	41	29	)	73	49	I	105	69	i
10	A	[LINE FEED]	42	2A	*	74	4A	J	106	6A	j
11	B	[VERTICAL TAB]	43	2B	+	75	4B	K	107	6B	k
12	C	[FORM FEED]	44	2C	,	76	4C	L	108	6C	l
13	D	[CARRIAGE RETURN]	45	2D	-	77	4D	M	109	6D	m
14	E	[SHIFT OUT]	46	2E	.	78	4E	N	110	6E	n
15	F	[SHIFT IN]	47	2F	/	79	4F	O	111	6F	o
16	10	[DATA LINK ESCAPE]	48	30	0	80	50	P	112	70	p
17	11	[DEVICE CONTROL 1]	49	31	1	81	51	Q	113	71	q
18	12	[DEVICE CONTROL 2]	50	32	2	82	52	R	114	72	r
19	13	[DEVICE CONTROL 3]	51	33	3	83	53	S	115	73	s
20	14	[DEVICE CONTROL 4]	52	34	4	84	54	T	116	74	t
21	15	[NEGATIVE ACKNOWLEDGE]	53	35	5	85	55	U	117	75	u
22	16	[SYNCHRONOUS IDLE]	54	36	6	86	56	V	118	76	v
23	17	[ENG OF TRANS. BLOCK]	55	37	7	87	57	W	119	77	w
24	18	[CANCEL]	56	38	8	88	58	X	120	78	x
25	19	[END OF MEDIUM]	57	39	9	89	59	Y	121	79	y
26	1A	[SUBSTITUTE]	58	3A	:	90	5A	Z	122	7A	z
27	1B	[ESCAPE]	59	3B	;	91	5B	[	123	7B	{
28	1C	[FILE SEPARATOR]	60	3C	<	92	5C	\	124	7C	
29	1D	[GROUP SEPARATOR]	61	3D	=	93	5D	]	125	7D	}
30	1E	[RECORD SEPARATOR]	62	3E	>	94	5E	^	126	7E	~
31	1F	[UNIT SEPARATOR]	63	3F	?	95	5F	_	127	7F	[DEL]

- Zur Realisierung von länderspezifischen Abweichungen steht der Code-Bereich [128 .. 255] für Zeichen wie z.B. "ä" (ASCII 132), "ö" (ASCII 148) "ü" (ASCII 129) zur Verfügung  
Weiterhin werden Zeichen dargestellt, mit denen man einfache graphische Darstellungen wie Rahmen und Schraffuren zusammensetzen kann.
- Diese Zeichen können über die numerische Tastatur eingegeben werden. Dazu muss diese aktiviert sein (dies geschieht durch die Taste "Num"), danach kann bei gedrückter "Alt"-Taste der dreistellige ASCII-Code eingegeben werden.
- Leider ist auch die Auswahl der sprachspezifischen Sonderzeichen eher zufällig und bei weitem nicht ausreichend für die vielfältigen Symbole fremder Schriften. Daher wurden von der „International Standardisation Organisation“ (ISO) verschiedene ASCII-Erweiterungen normiert. In Europa ist dazu die ASCII-Erweiterung Latin-1 nützlich, die durch die Norm ISO 8859-1 beschrieben wird.

- Neuer Standard: Unicode – versucht, sämtliche relevanten Zeichen aus den unterschiedlichsten Kulturkreisen in einem universellen Code zu vereinigen
- Version 1: Zunächst eine 16-Bit Codierung, folglich maximal 65.536 darstellbare Zeichen
- Die ersten 128 Zeichen des Unicode-Zeichensatzes sind identisch mit dem ASCII-Code, die folgenden 128 identisch mit ISO-Latin 1
- Unicode ist als UCS (Universal Character Set) bzw. als ISO-10646 vom Unicode-konsortium und der ISO standardisiert
- ISO geht in Definition von UCS noch einen Schritt weiter als das Unicode-Konsortium: Es werden sowohl eine 16-Bit Codierung (UCS-2) als auch eine 32-Bit Codierung (UCS-4) festgelegt
- Speicherung von Texten im Unicode benötigt zwei (UCS-2) bis viermal (UCS-4) soviel Speicherplatz, wie im ASCII-Code

Quelle: <http://www.hki.uni-koeln.de/>

- UTF ist andere Codierung von UCS bzw. Unicode
- UTF-8: Aufbau und Verfahren
  - UTF-8 ist eine Mehrbyte-Codierung (bis zu 4 Byte) bzw. ein Code von variabler Bit-Breite
  - ASCII-Zeichen werden bei UTF-8 mit 1 Byte codiert, in dem das erste Bit immer Null ist:  
`0xxx xxxx`
  - Jedes Byte, das mit einer 1 beginnt, gehört zu einem aus mehreren Bytes bestehenden UTF-8 Code: `110x xxxx 10xx xxxx = 2 Byte Code`
  - Besteht ein UTF-8 Code aus  $n \geq 2$  Bytes, beginnt das erste Byte (Startbyte) mit n Einsen, gefolgt von einer Null und jedes n-1 folgende Byte mit der Bitfolge 10 (siehe Beispiel oben)  
  
Ein 3-Byte Code sieht also folgendermaßen aus : `1110 xxxx 10xx xxxx 10xx  
xxxx`
  - Mit den 16 „verfügbaren“ Bits können alle 16-Bit UCS-2 Codes dargestellt werden
- UTF-8 codierte Dateien sind voll abwärtskompatibel zu 7-Bit ASCII und vergrößern den Umfang von Dateien aus dem amerikanischen und europäischen Bereich gar nicht oder nur unwesentlich

Quelle: <http://www.hki.uni-koeln.de/>

# Überblick UTF-8 Kodierung

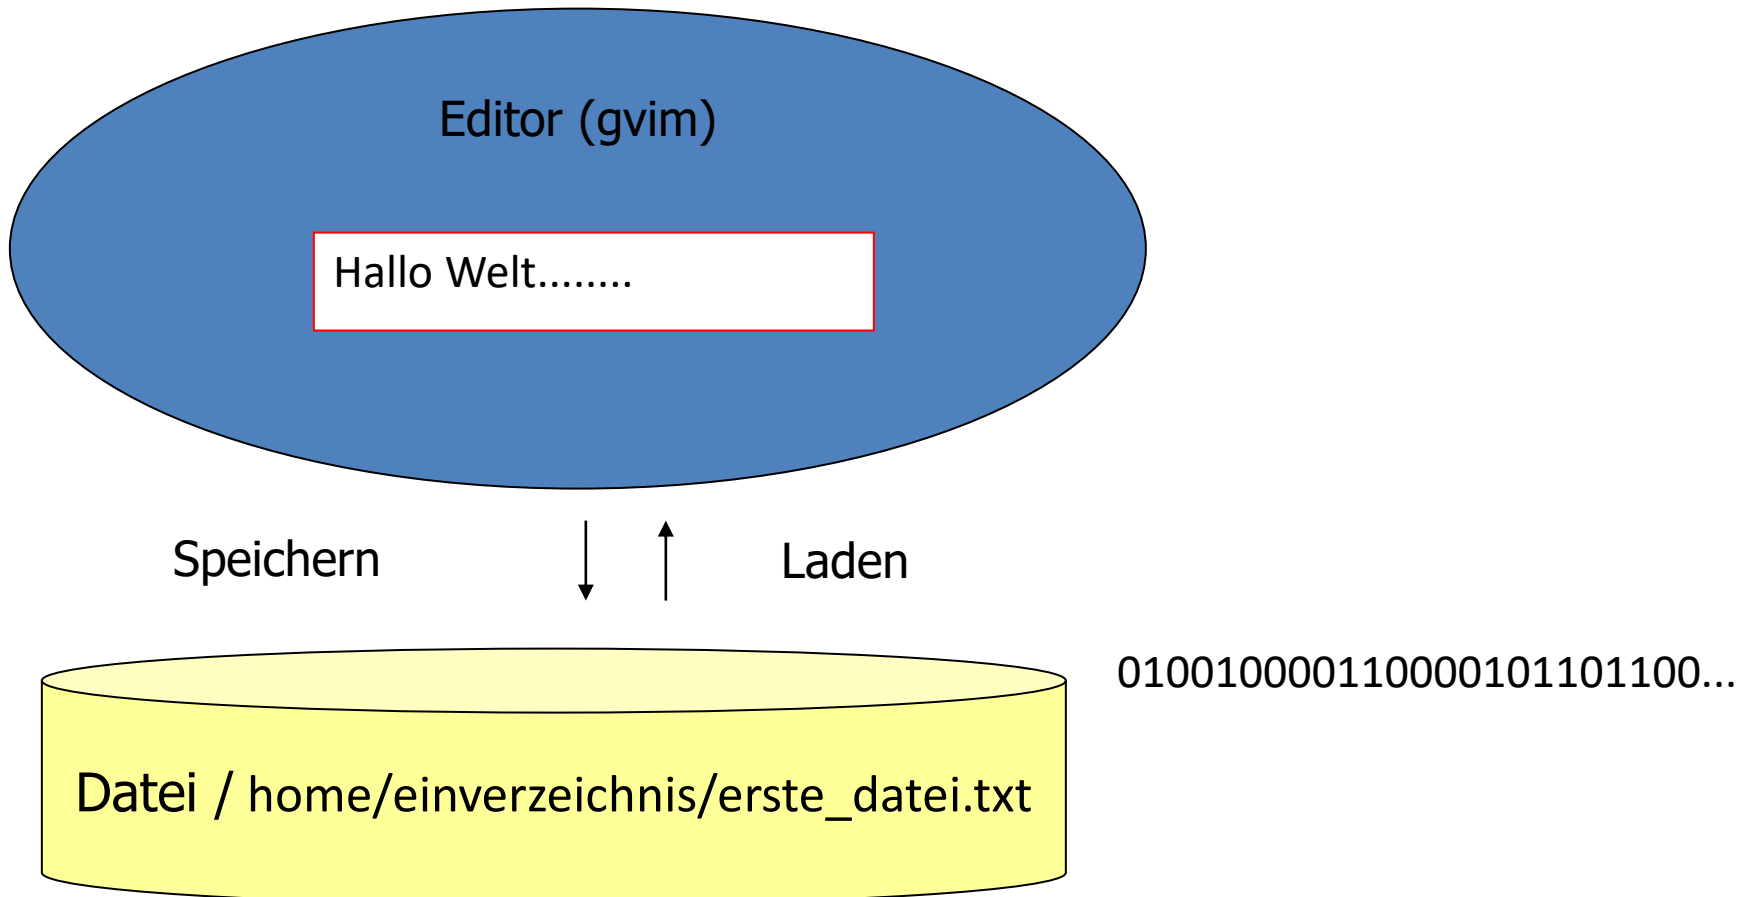
Unicode-Bereich	UTF-8 Kodierung	Bemerkung	Möglichkeiten (theoretisch)
0000 0000 – 0000 007F	0xxx xxxx	Bereich der dem ASCII-Code entspricht	$2^7 = 128$
0000 0080 – 0000 07FF	110xxxxx 10xxxxxx	Erstes Byte beginnt immer mit 110, die folgenden Bytes mit 10.	$2^{11} - 2^7 (2^{11})$ = 1920 (2048)
0000 0800 – 0000 FFFF	1110xxxx 10xxxxxx 10xxxxxx	Die xxxxx stehen für die Bits des Unicode-Zeichenwerts.	$2^{16} - 2^{11} (2^{16})$ = 63.488 (65.536)
0001 0000 – 0010 FFFF	11110xxx 10xxxxxx 10xxxxxx 10xxxxxx	Dabei wird das niederwertigste Bit des Zeichenwerts auf das rechte x im letzten Byte abgebildet, die höherwertigen Bits fortschreitend von rechts nach links. Die Anzahl der Einsen vor der ersten 0 im ersten Byte ist gleich der Gesamtzahl der Bytes für das Zeichen (In Klammern jeweils die theoretisch maximal möglichen).	$2^{20} (2^{21})$ = 1.048.576 (2.097.152)

Quelle: <http://de.wikipedia.org/wiki/UTF-8>

<b>2</b>	<b>Zahlen und Kodierung</b>
2.1	Kodierung
2.2	Bits und Bytes
2.3	Zahlsysteme 1 (natürliche Zahlen)
2.4	Konvertierung
2.5	Zahlsysteme 2 (ganze Zahlen)
2.6	Rechenoperation im Dualsystem
2.7	Zahlsysteme 3 (rationale und reelle Zahlen)
2.8	Textdarstellung
	2.9 Umgang mit Dateien

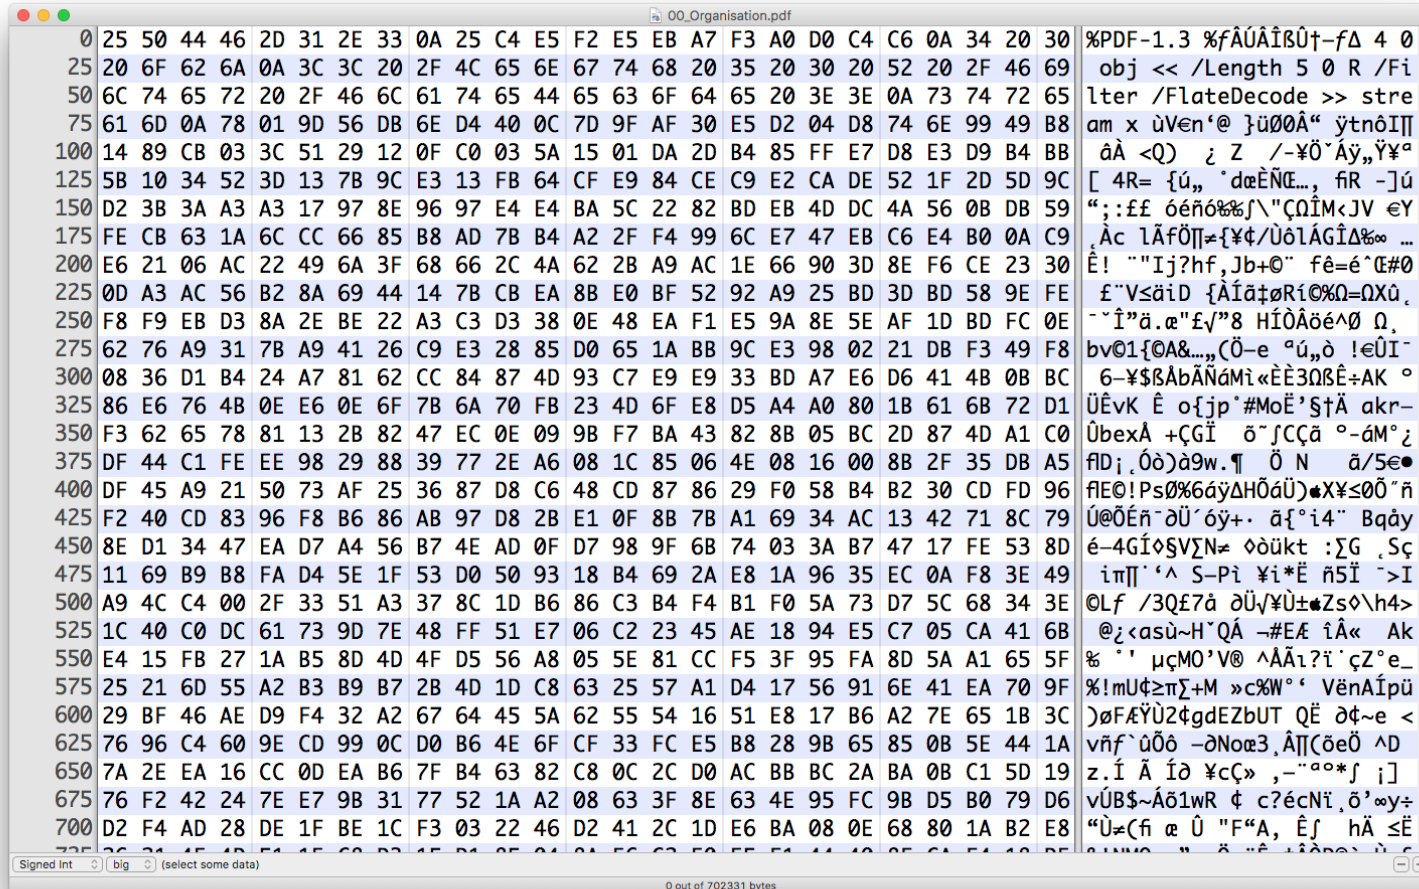
# Was ist eine Datei?

- Eine **Datei** ist eine Folge von Bits bzw. von Bytes. Dateien dienen dazu, Daten für längere Zeit (genauer: über eine Sitzung hinaus) zu speichern.
- So wie ein Buch einen Titel hat, hat eine Datei einen **Dateinamen**.
- Der **Dateiinhalt** ist eine Folge von Bits bzw. Bytes, die nach Maßgabe der **Datei-Beschreibung** (Protokoll) z.B. als (Binär-) Zahlen, Texte, Bilder, Graphiken, ausführbarer Programm-Code etc. interpretiert werden.
- Die **Erweiterung** des Namens (extension) gibt an, welcher Art die gespeicherten Daten sind (z.B. .doc, .txt, .ppt, .pas, .java, .exe).
- Dateien werden in **Verzeichnissen** zusammengefasst und können vom Betriebssystem über einen Pfad angesprochen werden, z.B. /home/einverzeichnis/erste\_datei.txt.





# HEX-Editor



- Sie kennen die Begriffe Codierung und Interpretation
- Sie kennen die üblichen Zahlensysteme (Ganze Zahlen, Gebrochene Zahlen)
- Sie können mit dem Dual-, Oktal, Hexadezimalsystem umgehen
- Sie können die Konvertierungsalgorithmen anwenden
- Sie kennen Rechenoperationen im Dualsystem
- Sie kennen übliche Codes zur Darstellung von Zeichen

